

Рекомендательная система для e-commerce

Персонализация товарных рекомендаций на основе поведения пользователей



Постановка задачи

Бизнес-цель:

- Увеличение продаж через персонализированные рекомендации
- 3 слота на главной странице сайта для рекомендаций

Техническая метрика:

- **Precision@3** - доля купленных товаров среди топ-3 рекомендаций
- Фокус на транзакциях (реальных покупках)

Baseline для сравнения:

- Популярные товары всем пользователям = 0.61%

Вызов:

Как превзойти простую стратегию популярности?



Описание данных

Масштаб проекта:

2.7М событий пользователей (май-сентябрь 2015)

1.4М пользователей, 235К товаров

1,669 категорий с иерархической структурой

1,100+ свойств товаров

Структура данных:

events.csv - поведение пользователей

- * **timestamp**: int64 - временная метка (миллисекунды)
- * **visitorid**: int64 - идентификатор пользователя
- * **event**: object - тип события (view, addtocart, transaction)
- * **itemid**: int64 - идентификатор товара
- * **transactionid**: float64 - ID транзакции (99% пропусков)

category_tree.csv - иерархия категорий

- * **categoryid**: int64 - идентификатор категории
- * **parentid**: float64 - родительская категория (пропуски = корневые)

item_properties.csv - характеристики товаров

- * **timestamp**: int64 - временная метка изменения
- * **itemid**: int64 - идентификатор товара
- * **property**: object - название свойства (categoryid, цена, доступность)
- * **value**: object - значение свойства (смешанные типы)




Воронка продаж и вызовы


1. Просмотры: 96.7%
2. Добавления в корзину: 2.5%
3. Покупки: 0.8%

Особенности данных:

- Только 0.8% событий — транзакции, что подчеркивает низкую конверсию
- Плотность матрицы взаимодействий $\sim 0.01\%$, что указывает на редкие взаимодействия между пользователями и товарами
- Данные охватывают 4.5 месяца (май–сентябрь 2015) с четкой последовательностью
- Много товаров и пользователей с минимальной активностью
- Минимальные проблемы с качеством данных (3 нулевых ID, 460 дубликатов, несовместимость типов категорий)



Matrix Factorization




LightFM (Гибридная модель):

- **Логика:** Объединяет коллаборативную фильтрацию с признаками товаров и пользователей (категории, цены, описания). Использует WARP loss для оптимизации ранжирования топ-k рекомендаций через градиентный спуск.
- **Преимущество:** Решает проблему холодного старта для новых пользователей и товаров благодаря использованию их признаков.

NMF (Неотрицательная матричная факторизация):

- **Логика:** Разлагает матрицу взаимодействий пользователей и товаров на две матрицы — латентные факторы пользователей и товаров. Эти факторы представляют скрытые предпочтения и характеристики, а рекомендации строятся через их произведение.
- **Преимущество:** Простота реализации и интерпретируемость результатов благодаря неотрицательным значениям факторов, что обеспечивает естественное представление предпочтений.

Hybrid Model



Итоги и перспективы

Итоговые результаты (Precision@3):

Baseline (популярные товары): 0.61%

NMF: 0.13%

LightFM: 0.15%

Анализ:

Результат ниже ожиданий из-за переобучения и разреженности данных

LightFM показал потенциал (1.52% на валидации), но упал до 0.15% на тесте

Уроки и выводы:

Нужна усиленная регуляризация и больше данных

Гибридный подход LightFM перспективен с доработкой

Следующие шаги:

Улучшать подбор гиперпараметров

Добавить новые признаки

Тестировать ансамбли моделей



Most needed